

Metodologia — Mapeamento de Cidades e Escolas Prioritárias (Case Poliedro)

1. Fontes de dados

Fonte	Edição	Uso
Censo Escolar INEP	2025 (mais recente disponível)	Universo de escolas, infraestrutura, situação de funcionamento
Microdados ENEM	2025	Desempenho acadêmico por escola
IBGE — Tabela 10296 (SIDRA)	Censo 2022	Renda domiciliar per capita por município
IBGE — Tabela 9514 (SIDRA)	Censo 2022	População 0-17 anos e população total por município

Justificativa de usar Censo Escolar 2025 (e não 2023, usado em versões anteriores deste projeto): é a edição mais recente e evita descompasso de ano com o ENEM 2025.

1.1. Fontes complementares avaliadas e não utilizadas

O case lista IBGE (PIB), Atlas Brasil/PNUD (IDH), REGIC/IBGE e QEdu como opcionais. Foram avaliadas e descartadas conscientemente:

Fonte	Por que não entrou
PIB per capita municipal (IBGE)	Mistura riqueza industrial/institucional com renda das famílias — viés já identificado neste projeto antes deste case. Renda domiciliar (Tabela 10296) é o substituto correto.
IDH Municipal (Atlas Brasil/PNUD)	Verificado em jul/2026: o IDHM oficial por município ainda usa base do Censo 2010 — não há atualização completa com o Censo 2022 (só uma estimativa parcial via PNAD Contínua, o “Radar IDHM”). Dado desatualizado demais para um recorte de mercado de 2025.
REGIC (regiões de influência das cidades, IBGE)	Responderia “qual cidade polariza a região”, pergunta diferente de “onde está a demanda e a oferta de prestígio privado hoje”. Redundante com o que população + renda + volume de escolas já capturam para este objetivo.
QEdu (indicadores educacionais consolidados)	Seus indicadores derivam do mesmo Censo Escolar e do próprio ENEM/Saeb — acessar as fontes primárias (que já fizemos) é mais rastreável do que uma camada consolidada de terceiros.

1.2. Critérios de exemplo do case não utilizados no score

- **Volume de matrículas no Ensino Médio** (QT_MAT_MED): coletado e exibido como contexto em ambas as partes, mas não pontua. Motivo: porte de matrícula mede tamanho, não prestígio — uma escola grande não é necessariamente mais prestigiada (e o exemplo do Censo 2025 mostrou porte podendo vir de dado inflado/mal preenchido, ver seção 7.4). Mesmo tratamento dado ao PIB per capita: informa a leitura, não decide o ranking.
- **Amplitude de segmentos ofertados (EI, EF, EM)**: não usada como critério de pontuação. Motivo: a amplitude de segmentos está mais associada a conveniência para a família (não trocar de escola do berçário ao 3º ano) do que a prestígio acadêmico — o objetivo deste case. Os dois critérios usados (ENEM + infraestrutura) já satisfazem o requisito mínimo de 2 critérios (1 Censo + 1 ENEM) com maior relação direta com a pergunta central.

2. Filtro de escopo (obrigatório, binário — não é critério de score)

- **Município**: população total > 100.000 habitantes → **319 municípios**.
- **Escola**: TP_DEPENDENCIA == 4 (privada) E TP_CATEGORIA_ESCOLA_PRIVADA em {1,2,3} (exclui 4 = Filantrópica) E TP_SITUACAO_FUNCIONAMENTO == 1 (em atividade) E QT_TUR_MED > 0 (Tabela_Turma_2025, oferece ao menos Ensino Médio).

Resultado: **8.095 escolas elegíveis nacionalmente**, das quais **5.647 estão em municípios >100k habitantes (318 dos 319 municípios — exceção: Ibirité/MG, sem escola elegível)**.

Limpeza de outliers de porte: removida 1 escola com 4.444 matrículas de Ensino Médio em 10 salas (444 alunos/sala — erro de preenchimento). QT_SALAS_UTILIZADAS está top-codado em 202 nesta edição (12 escolas distintas com valor idêntico) — por isso QT_MAT_MED (matrículas) é a métrica de porte usada, não salas.

3. Parte 1 — Score de priorização de cidades

Aplicado aos 318 municípios elegíveis. Cada critério é normalizado por percentil (rank/N, 0 a 1) dentro desse universo.

```
score_priorizacao = 0.40 × percentil(score_socioeconomico)
                  + 0.30 × percentil(qtd_escolas_elegiveis)
                  + 0.30 × percentil(enem_media_praca)
```

- **score_socioeconomico** (peso 0.40): $0.85 \times \text{score_renda} + 0.15 \times \text{percentil}(\text{população } 0-17)$, onde $\text{score_renda} = 0.80 \times \text{\%população em domicílios } >5 \text{ SM} + 0.20 \times \text{\%população em domicílios } 3-5 \text{ SM}$ (Tabela 10296). Não usa PIB per capita (mistura riqueza industrial/institucional com renda familiar real — lição já registrada neste projeto).
- **qtd_escolas_elegiveis** (peso 0.30): contagem de escolas elegíveis no município — é uma contagem simples (percentil do número de escolas), não pondera por porte nem qualidade; sinaliza concentração de mercado privado instalado, não riqueza.
- **enem_media_praca** (peso 0.30): média **ponderada por** qtd_participantes_enem (não é mais média simples das médias por escola — revisão de 21/07) do enem_media_geral (ver seção 5) das escolas elegíveis do município que têm dado ENEM vinculado. Motivo da revisão: a média simples dava o mesmo peso a uma escola de 15 participantes e a uma de 300 — a versão ponderada reflete melhor a praça como o aluno médio a experimenta. Municípios sem nenhuma escola com dado ENEM recebem o pior percentil (não são excluídos).

Resultado (versão ponderada): Top 10 = Belo Horizonte, Niterói, Goiânia, Vitória, Florianópolis, Brasília, Porto Alegre, São José dos Campos, Recife, Ribeirão Preto. Script:

poliedro_04_score_cidades.py.

Nota sobre São José dos Campos: é a sede nacional do Poliedro (CEV — Centro Empresarial do Vale, confirmado no site institucional). Sua presença no Top 10 provavelmente reflete um mercado onde a marca já tem forte presença, não uma oportunidade nova — leitura diferente das demais 9 cidades.

Resolvido (21/07): a mudança para média ponderada troca a 3ª colocação — Goiânia passa Vitória. Em vez de escolher entre as duas, a Parte 2 passou a usar as **4** cidades de maior score (Belo Horizonte, Niterói, Goiânia, Vitória) — cobre tanto a versão simples quanto a ponderada do critério, sem descartar nenhuma análise já validada, e ainda excede o mínimo de 3 cidades pedido pelo case.

4. Parte 2 — Score de destaque de escolas

Aplicado às 4 cidades de maior `score_priorizacao` (Belo Horizonte, Niterói, Goiânia, Vitória — topo do ranking da Parte 1, cobrindo tanto a versão simples quanto a ponderada do critério de qualidade ENEM). Percentis calculados sobre o universo nacional de 5.647 escolas elegíveis (não só dentro da cidade), para evitar instabilidade em praças com poucas escolas.

Nota sobre escopo do percentil (22/07): aqui (Parte 2, `poliedro_05_score_escolas.py`) o percentil é calculado sobre as 5.647 escolas elegíveis — mas isso não afeta o Top 5 de cada cidade (verificado: mesmas escolas, mesma ordem, mudando o escopo pra só as 4.121 com ENEM confiável — só o valor decimal do score varia ~0,005). Já o script irmão `poliedro_05b_score_destaque_nacional.py`, usado só para o funil/Golden Leads (seção 7, bônus de portfólio, não resposta formal ao case), calcula o percentil **só entre as 4.121 escolas com ENEM confiável** — porque ali a contagem final de Golden Leads É sensível ao escopo (869 com percentil só-confiáveis vs. 953 com percentil sobre as 5.647), e deixar escolas de amostra não-confiável “competirem” no percentil de quem é confiável seria inconsistente. Os 869/129 usados no deck e docs vêm desse segundo escopo.

Validação empírica: o Colégio Arena (Goiânia), 1º colocado na nova cidade, já aparece como depoimento de escola parceira no site institucional do Poliedro — um sinal de que o método aponta para escolas com fit real, não aleatório.

```
score_destaque = 0.60 * percentil(enem_media_geral) + 0.40 * percentil(indice_infra)
```

- **enem_media_geral** (peso 0.60, critério ENEM): média das 5 notas (CN, CH, LC, MT, Redação) dos participantes vinculados à escola (`CO_ESCOLA` em `RESULTADOS_2025.csv`), restrito a `TP_DEPENDENCIA_ADM_ESC==4` e `TP_SIT_FUNC_ESC==1`.
- **indice_infra** (peso 0.40, critério Censo): soma 0-5 de `IN_LABORATORIO_Ciencias` + `IN_LABORATORIO_INFORMATICA` + `IN_BIBLIOTECA` + `IN_QUADRA_ESPORTES_COBERTA` + `IN_AUDITORIO`.
- **Confiabilidade:** escolas com menos de 10 participantes ENEM vinculados não entram no ranking (média de amostra pequena é ruído, não sinal).
- `QT_MAT_MED` (matrículas) é reportado como contexto, não entra no score.

Script: `poliedro_05_score_escolas.py`. Resultado completo em `data/outputs/02_escolas_destaque_top3_cidade`

5. Extração ENEM 2025

`RESULTADOS_2025.csv` (nova estrutura 2025, ~4,8M linhas) filtrado por `CO_ESCOLA` não nulo + `TP_DEPENDENCIA_ADM_ESC==4` + `TP_SIT_FUNC_ESC==1` → 272.799 participantes em 8.200 escolas privadas. Script: `poliedro_02_extrair_enem.py`.

6. Bônus — Crescimento de matrículas de Ensino Médio (2023 → 2025)

Reaproveita `microdados_censo_escolar_2023.zip` (já estava na pasta de um exercício anterior; `QT_MAT_MED` já existia nesse schema, sem custo de novo download) cruzado por `CO_ENTIDADE` (código nacional de escola, estável entre edições) com `QT_MAT_MED` de 2025.

```
crescimento_pct = (QT_MAT_MED_2025 - QT_MAT_MED_2023) / QT_MAT_MED_2023 * 100
```

Cobertura: 85,8% das 5.647 escolas do recorte têm correspondência em 2023 (o restante são escolas novas ou mudança de código). Agregado por cidade usando **mediana** (não média), para não deixar 1-2 escolas com base muito pequena distorcerem o resultado (ex.: escola que foi de 2 para 56 matrículas gera crescimento de +2.687%, um valor real mas não representativo). Não altera os scores das Partes 1 e 2 — é uma coluna de contexto/momentum. Script: `poliedro_06_crescimento_matriculas.py`. Resultado: `data/outputs/03_crescimento_matriculas_2023_2025.csv`.

7. Ordem de execução (reprodutibilidade)

1. `poliedro_01_baixar_dados.py` — baixa Censo Escolar 2025 e população total IBGE (roda local, precisa de rede).
2. `poliedro_02_extrair_enem.py` — médias ENEM por escola.
3. `poliedro_03_extrair_censo.py` — escolas privadas elegíveis.
4. `poliedro_03b_extrair_enderecos.py` — endereço/CEP das escolas elegíveis (usado no passo 11).
5. `poliedro_04_score_cidades.py` — Parte 1.
6. `poliedro_05_score_escolas.py` — Parte 2 (Top 5 por cidade, resposta formal ao case).
7. `poliedro_05b_score_destaque_nacional.py` — mesmo `score_destaque`, mas sobre as 5.647 escolas nacionais (não só as 4 cidades) — base do funil e da segmentação comercial (bônus, passos 9-11). Gera `data/outputs/funil_escolas_pontuadas.csv`.
8. `poliedro_06_crescimento_matriculas.py` — bônus, crescimento 2023-2025 (opcional, não bloqueia os anteriores).
9. `poliedro_07_funil.py` — gera o gráfico de funil de priorização (8.095 → 5.647 → 4.121 → 869), terminando no universo único de Golden Leads (score ≥ 0,70). Contagens calculadas ao vivo a partir dos CSVs dos passos 3, 5b e 9 (não hardcoded).
10. `poliedro_08_visual_cosmos.py` — gera um visual procedural (estrelas + anéis concêntricos) usado no slide do Cosmos, sem dependência de internet/geração de imagem por IA.
11. `poliedro_09_icp_poliedro.py` — dentro do universo de 869 Golden Leads, tagueia cada escola com um segmento comercial baseado na posição dela no próprio município: Líder local (1º lugar), Desafiante (2º-5º lugar), Outras posições (6º+) ou Sem comparação local (cidade com <3 escolas confiáveis). Substitui a leitura anterior “129 Golden Leads vs 740 Qualificadas” — não é mais uma segunda faixa de score, é uma tag de posição dentro do mesmo universo. Gera `data/outputs/04_golden_leads_segmentadas.csv` (inclui `codigo_escola`, usado no passo 11).
12. `poliedro_10_segmentacao_comercial.py` — gráfico de barra segmentada com a distribuição dos 4 tags do passo 11.
13. `poliedro_11_geocodificar_ceps.py` — **roda localmente, precisa de internet** (o sandbox do assistente tem a rede bloqueada para APIs externas como ViaCEP). Geocodifica o CEP das Golden Leads das 10 cidades prioritárias para obter o bairro (primeiro passo de uma leitura geográfica mais fina que hoje só existe a nível de município). Não calcula renda por bairro — isso exigiria um pipeline maior com setor censitário do IBGE + geopandas, documentado como próximo passo no próprio script.
14. `poliedro_12_graficos_cidades.py` — gráficos Top10 e dispersão (tema escuro) a partir de `01_cidades_prioritarias.csv`.
15. `poliedro_13_detectar_salas_vitrine.py` — bônus, roda depois dos passos 2 e 3b. Detecta

nacionalmente o padrão de “sala vitrine” (unidade pequena com média ENEM muito acima das unidades-irmãs da mesma mantenedora/cidade) — generaliza a checagem ad-hoc feita sobre o Farias Brito. Gera data/outputs/13_salas_vitrine_suspeitas.csv.

8. Limitações documentadas

1. **Vínculo escola-participante mudou em 2025.** CO_ESCOLA (“código da escola de conclusão do ensino médio”, definição literal do dicionário) só existe em RESULTADOS_2025.csv, preenchido em 1.739.028 de 4.810.772 linhas (36,15%). IN_TREINEIRO e TP_ST_CONCLUSAO (que indicariam se o participante é treineiro/concluente — o que ajudaria a entender quem, entre os 63,85% sem escola, é pré-vestibulando vs. aluno regular) só existem em PARTICIPANTES_2025.csv. O próprio dicionário do INEP declara, em nota de rodapé, que a chave de RESULTADOS (NU_SEQUENCIAL) é “variável distinta da NU_INSCRICAO disponível na base de Participantes, de modo que não é possível utilizá-la para relacionar as duas bases” — ou seja, essas duas informações não podem ser cruzadas linha a linha nesta edição, o que impede reconstruir empiricamente a composição exata dos sem vínculo. Nota à parte: pré-vestibular não implica ausência de CO_ESCOLA — cursinhos que são eles próprios registrados como “escola” no Censo (ex.: unidades de pré-vestibular da rede Farias Brito) podem aparecer normalmente com CO_ENTIDADE próprio.
2. **Viés regional de adesão ao ENEM.** Em praças com forte oferta de vestibular próprio (ex.: São Paulo — USP, Unicamp, Unesp, transferências Unifesp/UFABC), parte dos melhores alunos de escolas de elite pode não priorizar o ENEM, subestimando essas escolas no score.
3. **“Salas vitrine” de redes de ensino.** Unidades pequenas de uma mesma rede/mantenedora, na mesma cidade, podem reportar médias infladas por usarem um grupo curado de alunos. Não é um caso isolado do Farias Brito: poliedro_13_detectar_salas_vitrine.py generaliza a checagem (agrupa por NU_CNPJ_MANTENEDORA + município, exclui o CNPJ-placeholder 99999999999999 de “mantenedora não informada”) e encontra **4 grupos confirmados nacionalmente** (rodado em 22/07): Christus Colégio Pré-Universitário (34 part., 779) vs. irmã de 74 part./654 — gap 125 pts; Farias Brito Colégio de Aplicação (30 part., 793) vs. 3 irmãs somando 565 part./670 — gap 123 pts; Colégio Gabarito, Uberaba/MG (31 part., 734) vs. irmã de 68 part./641 — gap 93 pts; Ari de Sá Cavalcante-Major Facundo (31 part., 766) vs. 3 irmãs somando 407 part./698 — gap 68 pts. Três dos quatro grupos são em Fortaleza/CE, um em Uberaba/MG — nenhum dos dois municípios está nas 10 cidades prioritárias nem entre as 4 do case formal, então **não afeta** as 20 escolas do Top 5×4 desta entrega, mas **afeta ~4 das 869 Golden Leads** (aparecem com score_destaque inflado e tag “Líder local”/alto rank no funil bônus). Todas passam no piso de 10 participantes — o filtro de confiabilidade mitiga ruído estatístico, mas não pega esse padrão específico.
4. **score_destaque (Parte 2) não mede renda familiar.** Testado cruzando o percentil de renda da cidade (Parte 1) com a posição de cada escola: percentil médio de renda da cidade é 0,85 nas escolas Líder/Desafiante de score mais alto e 0,74 nas demais Golden Leads — correlação positiva, porém moderada, não uma separação limpa por classe. O Censo Escolar não informa renda por aluno/família, então a tag de segmento comercial (seção 3, passo 9) é uma hipótese estratégica plausível, não uma segmentação por renda comprovada estatisticamente.
5. **Escolas filantrópicas excluídas** (categoria 4 do Censo — inclui APAE e similares) por não representarem o segmento de mercado privado relevante para este objetivo.
6. **Recorte nacional, não regional** — decisão de manter todas as 27 UF's em vez de restringir a uma região, dado que o volume de dados era processável no prazo.
7. **Segmento comercial (Líder/Desafiante) não sabe qual sistema de ensino a escola já usa.** Nenhuma fonte pública (Censo, ENEM, IBGE) informa isso. Piloto manual (busca individual, 21/07) nas 20 escolas de maior score_destaque nacional: cerca de metade já é dona do próprio sistema de ensino concorrente ou cliente declarada de um

sistema estabelecido (Ari de Sá Cavalcante = origem do SAS/Arco; Objetivo, Etapa e Gabarito = donas de sistema próprio; Master = cliente Eleva; Podion = cliente Sistema Anglo; Embraer/Juarez Wanderley = Rede Pitágoras/Kroton). As demais (Colégio Cognitivo, Colégio de São Bento, Marília Mattoso, Santo Agostinho, Liceu Jardim, Escola São Domingos) não sinalizam publicamente nenhum sistema comercial — sinal direcional, não confirmação; precisa de verificação individual antes de qualquer prospecção real. Liceu Jardim (Santo André) foi o único caso com declaração explícita de “não vinculado a nenhum sistema fechado”.

8. **Nome de arquivo desatualizado (cosmético).** `data/outputs/02_escolas_destaque_top3_cidades.csv` mantém o nome “top3” por compatibilidade com o restante do pipeline, mas contém as 4 cidades (Belo Horizonte, Niterói, Goiânia, Vitória) desde a revisão de 21/07.
9. **Sem benchmark setorial externo dedicado à educação básica privada.** Diferente de projetos anteriores deste portfólio que usaram o SEBRAE como benchmark (mercado geral de pequenos negócios), este projeto não incorporou uma fonte de contexto setorial externa — o Anuário Brasileiro da Educação Básica (Todos Pela Educação + Editora Moderna + Fundação Santillana, edição 2025 já inclui dado agregado da rede privada) é a fonte mais próxima de um “SEBRAE da educação básica” e não foi formalmente incorporada ao projeto, só usada para orientar esta resposta.